

تلاش‌هایی برای پیدا کردن کران بالایی بهتر برای مسئله بندیت پیوسته و لیپ‌شیتز


حامی عبادزاده مهدی دارابی

درس: آنالیز احتمالات ابعاد بالا
دانشگاه صنعتی شریف

۲ اسفند ۱۴۰۴

به نام خدا

- ۱ مقدمه و شهود مسئله
- ۲ تعریف رسمی: بندیت گسته
- ۳ UCB ۱
- ۴ بندیت پیوسته و فرض لیپ‌شیتز
- ۵ گسته‌سازی با ϵ - پوشش و سیاست پیشنهادی
- ۶ تلاش اول: کران بالا با گسته‌سازی
- ۷ تلاش دوم: ایده ناموفقِ کران با سوپریمم یک فرایند
- ۸ نتیجه‌گیری و مسیرهای ادامه



- در تصمیم‌گیری تکرارشونده، کیفیت واقعی گزینه‌ها از پیش معلوم نیست.
- باید هم‌زمان:
- **اکتشاف:** آزمون گزینه‌های کمترشناخته برای کسب اطلاعات،
- **بهره‌برداری:** استفاده از گزینه‌هایی که تاکنون بهتر بوده‌اند.
- **هدف:** کمینه کردن **پشیمانی** در افق زمانی.

- K بازو؛ برای هر بازو i دنباله پاداش‌ها $Y_{i,1}, Y_{i,2}, \dots$ مستقل و هم‌توزیع با توزیع ناشناخته P_i .
- $\mu_i := \mathbb{E}[Y_{i,1}]$ و فرض می‌کنیم پاداش‌ها در بازه $[0, 1]$ کراندارند.
- $T_i(n)$ تعداد دفعات انتخاب بازوی i تا پایان گام n .

$$\mathbb{E} \left[\sum_{i=1}^K \sum_{s=1}^{T_i(n)} Y_{i,s} \right] = \sum_{i=1}^K \mu_i \mathbb{E}[T_i(n)].$$

$$\mu^* := \max_{1 \leq i \leq K} \mu_i, \quad R(n) := \mu^* n - \sum_{i=1}^K \mu_i \mathbb{E}[T_i(n)].$$

هدف: طراحی سیاستی با $R(n)$ کوچک.

$$\hat{\mu}_i(t-1) = \frac{1}{T_i(t-1)} \sum_{s=1}^{T_i(t-1)} Y_{i,s}, \quad l_i(t) = \hat{\mu}_i(t-1) + \sqrt{\frac{2 \ln n}{T_i(t-1)}}.$$

- جمله اول: بهره‌برداری.
- جمله دوم: اکتشاف (عدم قطعیت).

۱ UCB

- ❶ مقداردهی اولیه: هر بازو $i = 1, \dots, K$ را دقیقاً یک بار انتخاب کن و پاداش را ثبت کن.
- ❷ برای هر گام $t = K + 1, \dots, T$:
 - برای هر بازو i شاخص زیر را محاسبه کنید:

$$I_i(t) = \hat{\mu}_i(t-1) + \sqrt{\frac{2 \ln n}{T_i(t-1)}}.$$

- بازوی با بیشترین شاخص را انتخاب کنید و پاداش را ثبت کنید.

(برای بازوهای زیربینه) $\Delta_i := \mu^* - \mu_i$

نتیجه کلاسیک

$$\mathbb{E}[T_i(n)] \leq \frac{\lambda \ln n}{\Delta_i^2} + 1 + \frac{\pi^2}{3}$$

$$R(n) \leq \sum_{i: \Delta_i > 0} \left(\frac{\lambda \ln n}{\Delta_i} + \left(1 + \frac{\pi^2}{3} \right) \Delta_i \right)$$

- فضای عمل: $\mathcal{X}$ (مثلاً زیرمجموعه‌ای فشرده از $\mathbb{R}^d$).
- در گام t عمل $X_t \in \mathcal{X}$ و پاداش $Y_t \in [0, 1]$.
- تابع میانگین: $f(x) = \mathbb{E}[Y_t \mid X_t = x]$ و $f^* = \sup_{x \in \mathcal{X}} f(x)$.

$$R(n) = \sum_{t=1}^n \mathbb{E}[f^* - f(X_t)].$$

اگر برای ثابت $L > 0$ داشته باشیم

$$|f(x) - f(x')| \leq L d(x, x') \quad (\forall x, x' \in \mathcal{X}),$$

آنگاه اعمال نزدیک، میانگین پاداش نزدیک دارند و «ساختار هندسی» قابل استفاده می‌شود.



پیام شهودی

اگر ورودی‌ها (نقاط) نزدیک باشند، خروجی‌ها نمی‌توانند «پرش» بزرگی داشته باشند؛ شیب تغییرات با یک ثابت L کنترل می‌شود.

مثال قیمت‌گذاری و توجیه فرض لیپ‌شیتز

سناریو (کنش = قیمت)

فرض کنید کنش شما انتخاب یک قیمت باشد:

$$x \in [0, 1].$$

در هر مرحله، قیمت x را اعلام می‌کنید و درآمد تصادفی زیر را مشاهده می‌کنید:

$$Y = x \cdot 1 \{\text{مشتري با قیمت } x \text{ خرید می‌کند}\}.$$

تابع میانگین پاداش

تابع پاداش میانگین (میانگین شرطی درآمد) برابر است با:

$$f(x) = \mathbb{E}[Y | X = x] = x p(x),$$

که در آن $p(x)$ احتمال خرید در قیمت x است.

در بسیاری از بازارها، تغییرات کوچک در قیمت معمولاً باعث «جهش ناگهانی» در $p(x)$ نمی‌شود؛ پس $p(x)$ و در نتیجه $f(x)$ به‌طور تدریجی تغییر می‌کنند. این دقیقاً همان شهودی است که فرض لیپ‌شیتز برای f بیان می‌کند.

اگر $(\mathcal{X}, d)$ فضای متریک باشد، $N_\varepsilon \subset \mathcal{X}$ یک ε -پوشش است اگر:

$$\forall x \in \mathcal{X} \exists \tilde{x} \in N_\varepsilon : d(x, \tilde{x}) \leq \varepsilon$$

اگر

$$N_\varepsilon = \{x_1, \dots, x_K\}, \quad K := |N_\varepsilon|$$

می‌توان نقاط شبکه را به عنوان بازوهای یک مسئله گسسته در نظر گرفت و UCB ۱ را روی آن اجرا کرد.

پرسش اصلی

اگر در مسئله‌ی بندیت پیوسته با پاداش‌های کراندار، تابع میانگین پاداش f لیپ‌شیتز باشد، آیا می‌توان با گسسته‌سازی فضای عمل از طریق یک ε -پوشش و اجرای مستقیم الگوریتم UCB1 روی مجموعه‌ی گسسته‌ی N_ε ، به کران پشیمانی‌ای دست یافت که (با انتخاب مناسب ε) از کران ارائه‌شده در حالت پیوسته (قضیه ۱) بهتر باشد؟

- فضای عمل: $\mathcal{X}$ ، تابع میانگین: $f: \mathcal{X} \rightarrow [0, 1]$.
- $N_\varepsilon \subset \mathcal{X}$ یک ε -پوشش و $|N_\varepsilon| < \infty$.
- سیاست پیشنهادی: محدود کردن انتخاب‌ها به N_ε و اجرای UCB1 روی آن.

تلاش‌ها

تلاش اول: گسسته‌سازی با ε - پوشش و اجرای UCB1

- ایده: فضای پیوسته‌ی عمل $\mathcal{X}$ را با یک ε -پوشش N_ε تقریب می‌زنیم و انتخاب‌ها را به N_ε محدود می‌کنیم.
- سپس مسئله به یک بندیت گسسته با $K := |N_\varepsilon|$ بازو تبدیل می‌شود و UCB1 را روی این K بازو اجرا می‌کنیم.
- پشیمانی کل به دو مؤلفه تفکیک می‌شود:

(پشیمانی روی شبکه) + (خطای گسسته‌سازی)

- در ادامه، ε را طوری انتخاب می‌کنیم که این دو مؤلفه متعادل شوند.

ایده اصلی

فقط از مجموعه محدود N_ϵ عمل انتخاب کنید:

$$X_t \in N_\epsilon$$

و UCB۱ را روی بازوهای متناظر با $\{x_1, \dots, x_K\}$ اجرا کن، با میانگین بازوی i برابر:

$$\mu_i = f(x_i)$$

پشیمانی نسبت به بهینه پیوسته:

$$R(n) = \sum_{t=1}^n (\mathbb{E}[f^* - f(X_t)])$$

لم ۱: خطای تقریب شبکه (کنترل با لیپشیتز)

بیان لم و اثبات کوتاه

فرض کنید N_ε یک ε -پوشش از χ و f با ثابت L لیپشیتز باشد. تعریف کنید

$$f^* := \sup_{x \in \chi} f(x), \quad f_\varepsilon^* := \max_{x \in N_\varepsilon} f(x).$$

آنگاه

$$0 \leq f^* - f_\varepsilon^* \leq L\varepsilon.$$

اثبات کوتاه. بگذارید $x^* \in \arg \max_{x \in \chi} f(x)$. چون N_ε یک ε -پوشش است، نگاشتی $\pi : \chi \rightarrow N_\varepsilon$ وجود دارد به طوری که

$$d(x, \pi(x)) \leq \varepsilon \quad (\forall x \in \chi).$$

در نتیجه

$$f^* = f(x^*) \leq f(\pi(x^*)) + L\varepsilon \leq f_\varepsilon^* + L\varepsilon.$$

پس $f^* - f_\varepsilon^* \leq L\varepsilon$ و از طرفی بدیهی است $f_\varepsilon^* \leq f^*$.

اگر $X_t \in N_\varepsilon$ (یعنی سیاست فقط از نقاط شبکه انتخاب کند)، آنگاه

$$R(n) := \sum_{t=1}^n (\mathbb{E}[f^* - f(X_t)]) = \sum_{t=1}^n (\mathbb{E}[f^* - f_\varepsilon^*]) + \sum_{t=1}^n (\mathbb{E}[f_\varepsilon^* - f(X_t)]) \leq L\varepsilon n + R_n^\varepsilon,$$

که در آن

$$R_n^\varepsilon := \sum_{t=1}^n (\mathbb{E}[f_\varepsilon^* - f(X_t)])$$

پشیمانی نسبت به بهترین نقطه روی شبکه است.

لم ۲: کران مستقل از فاصله برای ۱UCB روی K بازو

در مسئله گسسته با K بازو و پاداش‌های $[0, 1]$ ، پشیمانی مورد انتظار ۱UCB پس از T گام:

$$R_n^\varepsilon \leq 4\sqrt{2K \times n \ln(n)} + \left(1 + \frac{\pi^2}{3}\right)K$$

- ایده اثبات: بازوها را با آستانه α به «نزدیک بهینه» و «دور از بهینه» تقسیم می‌کنیم.
- برای نزدیک بهینه‌ها: $\alpha n \leq$.
- برای دورها: از کران کلاسیک $\mathbb{E}[T_i(n)]$ استفاده می‌کنیم.
- انتخاب بهینه $\alpha = \sqrt{(\lambda K \ln(n))/n}$ دو جمله اصلی را هم مرتبه می‌کند.

ترکیب لم‌ها: کران نهایی تلاش اول

از لم ۱ و لم ۲:

$$R(n) \leq L\epsilon n + 4\sqrt{2K \times n \ln(n)} + \left(1 + \frac{\pi^2}{3}\right)K$$

برای $\mathcal{X} = [0, 1]^d$ با متریک $\|\cdot\|_\infty$ می‌توان پوششی با

$$K = |N_\epsilon| \lesssim \left(\frac{1}{\epsilon} + 1\right)^d \approx \epsilon^{-d}$$

در نظر گرفت.
با انتخاب

$$\epsilon := n^{-1/(d+2)} \quad \Rightarrow \quad K = \epsilon^{-d} = n^{d/(d+2)}$$

به دست می‌آید:

$$R(n) \leq L n^{\frac{d+1}{d+2}} + 4\sqrt{2 \ln(n)} n^{\frac{d+1}{d+2}} + \left(1 + \frac{\pi^2}{3}\right) n^{\frac{d}{d+2}}.$$

- سیاست ساده: شبکه‌سازی ε و اجرای مستقیم UCB روی شبکه.
- دو منبع پشیمانی:
 - خطای گسسته‌سازی: $L\varepsilon n$
 - پشیمانی گسسته UCB روی K بازو
- بهینه‌سازی ε نرخ اصلی را از جنس $n^{\frac{d+1}{d+2}}$ (با عامل $\sqrt{\ln(n)}$) می‌دهد.

تلاش دوم (ناموفق): بازنویسی پشیمانی به صورت کران از بالا برای امید سوپریمم یک فرایند

انگیزه

ایده‌ی این تلاش استفاده از لم زیر بود که «امید سوپریمم» یک فرایند تصادفی لیپ‌شیتز و زیرگوسی را با عدد پوشش کنترل می‌کند. به طور خلاصه، اگر $\{Z_t\}_{t \in T}$ یک فرایند لیپ‌شیتز و زیرگوسی باشد، آنگاه کرانی از شکل زیر برقرار است:

$$\mathbb{E} \left[\sup_{t \in T} Z_t \right] \leq \varepsilon \mathbb{E}[C] + \sqrt{2\sigma^2 \log N(T, d, \varepsilon)}.$$

در این جا C ثابت لیپ‌شیتز، σ^2 پارامتر زیرگوسی است.

هدف: بازنویسی پشیمانی به شکل

$$R(n) \leq \mathbb{E} \left[\sup_{x \in \mathcal{X}} Z_x \right]$$

به گونه‌ای که فرایند $\{Z_x\}_{x \in \mathcal{X}}$:

- نسبت به x لیپ‌شیتز باشد،

- زیرگوسی مرکزدار باشد،

تا بتوان امید سوپریمم را با عدد پوشش کنترل کرد.

انتخاب صوری:

$$Z_x := n \times f(x) - \sum_{t=1}^n f(X_t)$$

• اگر $x^* \in \arg \max f(x)$ ، آنگاه Z_{x^*} «شبه» پشیمانی مبتنی بر f است.

• اگر f لیپ‌شیتز باشد:

$$|Z_x - Z_{x'}| = n \times |f(x) - f(x')| \leq n \times L d(x, x')$$

پس فرایند نسبت به x لیپ‌شیتز است.

• چون $f(\cdot) \in [0, 1]$ ، داریم $-n \leq Z_x \leq n$ و در نتیجه کران‌دار/زیرگوسی است.

مشکل اصلی: Z_x مرکزی نیست:

$$\mathbb{E}[Z_x] = n \times f(x) - \sum_{t=1}^n \mathbb{E}[f(X_t)] \neq 0$$

اگر مرکزی کنیم:

$$\tilde{Z}_x := Z_x - \mathbb{E}[Z_x]$$

آنگاه:

$$\tilde{Z}_x = \left(n \times f(x) - \sum_{t=1}^n f(X_t) \right) - \left(n \times f(x) - \sum_{t=1}^n \mathbb{E}[f(X_t)] \right) = - \sum_{t=1}^n f(X_t) + \sum_{t=1}^n \mathbb{E}[f(X_t)]$$

که دیگر به x وابسته نیست. پس:

$$\sup_{x \in \mathcal{X}} \tilde{Z}_x = \tilde{Z}_x, \quad \mathbb{E} \left[\sup_{x \in \mathcal{X}} \tilde{Z}_x \right] = \mathbb{E}[\tilde{Z}_x] = 0$$

بنابراین این مسیر در بهترین حالت «کران صفر» برای کمیت مرکزی می‌دهد و عملاً کران مفیدی برای پشیمانی تولید نمی‌کند.

چون در هر گام:

$$0 \leq f^* - f(X_t) \leq 1$$

داریم:

$$0 \leq R(n) = \sum_{t=1}^n \mathbb{E}[f^* - f(X_t)] \leq n \Rightarrow R(T) \leq n$$

و تلاش دوم در نهایت به چیزی بهتر از این نرخ عمومی نرسید.

- هدف: کران‌گذاری پشیمانی با بازنویسی آن به شکل $\mathbb{E}[\sup_{x \in \mathcal{X}} Z_x]$ و استفاده از لم سوپریمم فرایند لیپ‌شیتز-زیرگاوسی.
- مانع: نتوانستیم فرایندی بسازیم که هم وابستگی به x را حفظ کند و هم مرکزدار/زیرگاوسی باشد.
- نتیجه: بهترین کران حاصل هم‌مرتبه با کران بدیهی $R(n) \leq n$ (یعنی $O(n)$) شد.

- تلاش اول (موفق): گسسته سازی با ε -پوشش + UCB

$$R(n) \lesssim n^{\frac{d+1}{d+2}} \sqrt{\ln(n)} \quad (\text{جملات پایین تر} +)$$

- تلاش دوم (ناموفق): ساخت فرایند Z_x برای کنترل $\mathbb{E}[\sup_x Z_x]$

- چالشِ مرکزدار بودن و حفظ وابستگی به x
- مرکزی سازی وابستگی به x را از بین برد

Fischer. Paul and Cesa-Bianchi, Nicolò Auer, Peter 
problem. bandit multiarmed the of analysis Finite-time
Learning Machine, ۴۷ (۲-۳): ۲۳۵-۲۵۶, ۲۰۰۲.