



تلاش‌هایی برای پیدا کردن کران بالایی بهتر برای مسئله بندیت پیوسته و لیپ‌شیتز

درس: آنالیز احتمالاتی ابعاد بالا

تهیه‌کنندگان:

مهدی دارابی

حامی عبادزاده سمنانی

استاد: دکتر محمدحسین یاسائی میبدی

دانشگاه صنعتی شریف

۴ اسفند ۱۴۰۴

فهرست مطالب

۴.۲.۵ جمع‌بندی نتیجه‌ی این تلاش . . . ۶

۱	مقدمه	۲	پیوست‌ها	۶
۲	تعریف مسئله (حالت گسسته و پاداش‌های کران‌دار)	۲		
۳	نمونه‌ای از سیاست‌های یادگیری در بندیت چند بازو	۲		
۱.۳	الگوریتم UCB۱	۲		
۲.۳	کران پشیمانی سیاست UCB۱	۳		
۴	مسئله پیشنهادی	۳		
۱.۴	مسئله‌ی بندیت پیوسته با پاداشِ کران‌دار	۳		
۲.۴	فرض لیپ‌شیتز بودن f و توجه آن	۳		
۳.۴	گسسته‌سازی فضا با ϵ -پوشش	۴		
۴.۴	مسئله پیشنهادی	۴		
۵	تلاش‌ها	۴		
۱.۵	تلاش اول : گسسته‌سازی با ϵ -پوشش و کران مستقل از فاصله	۴		
۱.۱.۵	سیاست «گسسته‌سازی + UCB1»	۴		
۲.۱.۵	گام اول: کنترل خطای گسسته‌سازی با لیپ‌شیتز	۴		
۳.۱.۵	گام دوم: کران مستقل از فاصله برای UCB1 روی K بازو	۵		
۴.۱.۵	ترکیب دو گام و بهینه‌سازی ϵ	۵		
۲.۵	تلاش دوم (ناموفق): بازنویسی پشیمانی به‌صورت کران از بالا برای امیدِ سوپریمم یک فرایند	۵		
۱.۲.۵	ایده‌ی کلی و مانع اصلی	۵		
۲.۲.۵	یک مثال «بد» برای شهود	۵		
۳.۲.۵	کران بدیهی پشیمانی	۶		

به نام خدا

مقاله پاداش‌ها کران دارند؛ یعنی برای هر i ،

$$\text{supp}(P_i) \subseteq [0, 1].$$

۱ مقدمه

یک سیاست یا Policy در هر گام $t = 1, 2, \dots$ یک بازو را انتخاب می‌کند. اگر $T_i(n)$ تعداد دفعات انتخاب بازوی i تا پایان گام n باشد، آنگاه پاداش تجمعی مورد انتظار برابر است با

$$\mathbb{E} \left[\sum_{i=1}^K \sum_{s=1}^{T_i(n)} Y_{i,s} \right] = \sum_{i=1}^K \mu_i \mathbb{E}[T_i(n)].$$

بازوی بهینه را با

$$\mu^* := \max_{1 \leq i \leq K} \mu_i$$

تعریف می‌کنیم. و در نهایت پشیمانی یا Regret پس از n گام برابر است با

$$R(n) := \mu^* n - \sum_{i=1}^K \mu_i \mathbb{E}[T_i(n)].$$

هدف مسئله: طراحی سیاستی که regret را کمینه کند؛ یعنی برای افق n تا حد امکان مقدار $R(n)$ کوچک باشد.

در بسیاری از مسائل تصمیم‌گیری، باید به صورت تکرارشونده یکی از چند گزینه را انتخاب کنیم، در حالی که کیفیت واقعی هر گزینه از پیش معلوم نیست و فقط با آزمون و مشاهده پیامدها آشکار می‌شود. مسئله Multi-Armed Bandit یک چارچوب ساده برای مدل‌سازی همین وضعیت است و هسته اصلی آن «موازنه‌ی اکتشاف/بهره‌برداری» است: از یک سو باید گزینه‌های کمترشناخته را امتحان کرد تا اطلاعات به دست آید (اکتشاف)، و از سوی دیگر باید تا حد ممکن از گزینه‌ای استفاده کرد که تاکنون بهتر عمل کرده است (بهره‌برداری).

این چارچوب در کاربردهای متعددی ظاهر می‌شود؛ برای مثال در تبلیغات و A/B-test، سامانه‌های پیشنهاددهنده، بهینه‌سازی برخط تجربه کاربری، و تخصیص منابع در شرایط عدم قطعیت. هدف، به طور کلی، بیشینه‌سازی عملکرد تجمعی در طول زمان است، در حالی که یادگیری نیز هم‌زمان با تصمیم‌گیری رخ می‌دهد.

۲ تعریف مسئله (حالت گسسته و پاداش‌های کران‌دار)

تعریف این بخش مطابق مقاله‌ی Auer, Cesa-Bianchi, and Fischer (2002) است [۱] و ممکن است در برخی منابع دیگر متفاوت ارائه شود.

مسئله Multi-Armed Bandit با K بازو به صورت زیر مدل می‌شود. برای هر بازو $i \in \{1, \dots, K\}$ ، دنباله‌ی پاداش‌ها

$$Y_{i,1}, Y_{i,2}, \dots$$

مستقل و هم‌توزیع با توزیع ناشناخته‌ی P_i هستند و

$$\mu_i := \mathbb{E}[Y_{i,1}]$$

امید پاداش بازوی i را نشان می‌دهد. همچنین دنباله‌های پاداش بازوهای مختلف نسبت به هم مستقل فرض می‌شوند. در این

۳ نمونه‌ای از سیاست‌های یادگیری در بندیت چند بازو

۱.۳ الگوریتم UCB1

الگوریتم UCB1 که در [۱] معرفی شده است، برای هر بازو در هر گام یک «شاخص» تعریف می‌کند و بازویی را انتخاب می‌کند که این شاخص بیشترین مقدار را داشته باشد. اگر تا گام $t-1$ ، بازوی i تعداد $T_i(t-1)$ بار انتخاب شده باشد، میانگین تجربی آن برابر است با

$$\hat{\mu}_i(t-1) = \frac{1}{T_i(t-1)} \sum_{s=1}^{T_i(t-1)} Y_{i,s}.$$

در گام t شاخص بازوی i به صورت

$$I_i(t) = \hat{\mu}_i(t-1) + \sqrt{\frac{2 \ln t}{T_i(t-1)}}$$

تعریف می‌شود و بازویی انتخاب می‌شود که $I_i(t)$ را بیشینه کند.

جمله‌ی اول بیانگر برآورد فعلی کیفیت بازو (بهره‌برداری) و جمله‌ی دوم بیانگر میزان عدم قطعیت نسبت به آن (اکتشاف) است. هرچه بازویی کمتر آزموده شده باشد، جمله‌ی دوم بزرگ‌تر است و الگوریتم آن را برای جمع‌آوری اطلاعات بیشتر ترجیح می‌دهد. در آغاز اجرا، هر بازو یک‌بار انتخاب می‌شود تا میانگین تجربی آن تعریف گردد.

۲.۳ کران پشیمانی سیاست UCB۱

قضیه ۱.۳. فرض کنید پاداش‌ها در بازه‌ی $[0, 1]$ کران‌دار باشند. اگر از الگوریتم $UCB1$ استفاده شود، آنگاه برای هر بازوی زیربینه i یعنی $0 < \mu^* - \mu_i = \Delta_i$ ، تعداد انتخاب‌های مورد انتظار آن تا گام n دارای کران زیر است:

$$\mathbb{E}[T_i(n)] \leq \frac{8 \ln n}{\Delta_i^2} + 1 + \frac{\pi^2}{3}.$$

در نتیجه، پشیمانی کل دارای کران لگاریتمی زیر خواهد بود:

$$R(n) \leq \sum_{i: \Delta_i > 0} \left(\frac{8 \ln n}{\Delta_i} + \left(1 + \frac{\pi^2}{3} \right) \Delta_i \right).$$

۴ مسئله پیشنهادی

قبل از بیان مسئله پیشنهادی نیاز به تعریف چند مطلب داریم.

۱.۴ مسئله‌ی بندیت پیوسته با پاداش کران‌دار

در بندیت پیوسته، فضای عمل یک مجموعه‌ی $\mathcal{X}$ است (عموماً $\mathcal{X} \subset \mathbb{R}^d$). در هر گام $t = 1, 2, \dots$ عامل یک عمل انتخاب می‌کند

$$X_t \in \mathcal{X},$$

و سپس پاداش تصادفی کران‌دار مشاهده می‌شود

$$Y_t \in [0, 1].$$

تابع میانگین پاداش به صورت

$$f: \mathcal{X} \rightarrow [0, 1], \quad f(x) := \mathbb{E}[Y_t | X_t = x]$$

تعریف می‌شود. همچنین

$$f^* := \sup_{x \in \mathcal{X}} f(x)$$

و پشیمانی مورد انتظار پس از n گام برابر است با

$$R(n) := \sum_{t=1}^n \mathbb{E}[f^* - f(X_t)].$$

هدف، مانند قبل طراحی سیاستی است که $R(n)$ را کمینه کند.

۲.۴ فرض لیپ‌شیتز بودن f و توجیه آن

در بسیاری از کارهای مربوط به بندیت پیوسته، علاوه بر کران‌دار بودن پاداش، فرض می‌شود تابع میانگین پاداش f روی $\mathcal{X}$ لیپ‌شیتز است؛ یعنی عددی $L > 0$ وجود دارد به طوری که برای هر $x, x' \in \mathcal{X}$

$$|f(x) - f(x')| \leq L \times d(x, x').$$

این فرض بیان می‌کند که «اعمال نزدیک» باید میانگین پاداش نزدیک داشته باشند.

با وجود اینکه این توابع بسیار بسیار محدود هستند، این فرض در برخی کاربردها نامعقول نیست. فرض کنید کنش یک «قیمت» باشد:

$$x \in [0, 1].$$

در هر مرحله، شما قیمت x را اعلام می‌کنید و «درآمد» تصادفی زیر را مشاهده می‌کنید:

$$Y = x \cdot \mathbf{1}\{\text{مشتري با قيمت } x \text{ خريد مي كند}\}.$$

تابع پاداش میانگین (میانگین شرطی پاداش) را به صورت زیر تعریف می‌کنیم:

$$f(x) = \mathbb{E}[Y | X = x] = x p(x),$$

که در آن $p(x)$ احتمال خرید در قیمت x است.

در بسیاری از بازارها، تغییرات کوچک در قیمت معمولاً باعث «جهش‌های ناگهانی» در احتمال خرید نمی‌شود؛ به بیان دیگر، $p(x)$ (و در نتیجه $f(x)$) معمولاً با تغییرات کوچک x به طور تدریجی تغییر می‌کند. این شهود همان چیزی است که فرض لیپ‌شیتز برای f بیان می‌کند.

۳.۴ گسسته‌سازی فضا با ϵ -پوشش

یک راه برای استفاده از یک سیاست گسسته در مسئله‌ی بندیت پیوسته این است که یک ϵ -پوشش از $\mathcal{X}$ بسازیم. فرض کنید $(\mathcal{X}, d)$ یک فضای متریک است و $N_\epsilon \subseteq \mathcal{X}$ یک ϵ -پوشش متناهی باشد؛ یعنی برای هر $x \in \mathcal{X}$ نقطه‌ای $\tilde{x} \in N_\epsilon$ وجود دارد به‌طوری‌که $d(x, \tilde{x}) \leq \epsilon$. در این صورت با تعریف

$$K := |N_\epsilon|, \quad N_\epsilon = \{x_1, \dots, x_K\},$$

می‌توان نقاط $x_1, \dots, x_K$ را به‌عنوان بازوهای یک مسئله‌ی گسسته در نظر گرفت و برای نمونه الگوریتم UCB1 را روی این مجموعه اجرا کرد.

۴.۴ مسئله پیشنهادی

پرسش اصلی. اگر در مسئله‌ی بندیت پیوسته با پاداش کران‌دار، تابع میانگین پاداش f لیپ‌شیتز باشد، آیا می‌توان با گسسته‌سازی فضای عمل از طریق یک ϵ -پوشش و اجرای مستقیم الگوریتم UCB1 روی مجموعه‌ی N_ϵ ، به کران پشیمانی‌ای دست یافت که (پس از انتخاب مناسب ϵ) از کران ارائه‌شده در قضیه‌ی مربوط به حالت پیوسته (قضیه‌ی ۱) بهتر باشد؟

۵ تلاش‌ها

۱.۵ تلاش اول: گسسته‌سازی با ϵ -پوشش و کران مستقل از فاصله

در این بخش «تلاش اول» پروژه را به‌صورت دقیق صورت‌بندی و کران بالا را استخراج می‌کنیم. فرض می‌کنیم $\mathcal{X} = [0, 1]^d$ و پاداش‌ها کران‌دارند $(Y_t \in [0, 1])$. همچنین تابع میانگین پاداش $f: \mathcal{X} \rightarrow [0, 1]$ نسبت به متریک $d(\cdot, \cdot)$ لیپ‌شیتز با ثابت L است:

$$|f(x) - f(x')| \leq L d(x, x') \quad (\forall x, x' \in \mathcal{X}).$$

(برای آنکه اندازه‌ی پوشش دقیقاً از مرتبه‌ی ϵ^{-d} شود، می‌توان d را به‌عنوان $d(x, x') = \|x - x'\|_\infty$ در نظر گرفت.)

۱.۱.۵ سیاست «گسسته‌سازی + UCB1»

یک ϵ -پوشش متناهی $N_\epsilon = \{x_1, \dots, x_K\} \subset \mathcal{X}$ می‌کنیم، یعنی برای هر $x \in \mathcal{X}$ نقطه‌ای $\tilde{x} \in N_\epsilon$ وجود دارد که $d(x, \tilde{x}) \leq \epsilon$. سپس در هر گام t تنها یکی از نقاط شبکه را انتخاب می‌کنیم:

$$X_t \in N_\epsilon,$$

و الگوریتم UCB1 را روی K بازوی متناظر با نقاط $x_1, \dots, x_K$ اجرا می‌کنیم. میانگین بازوی i برابر خواهد بود با:

$$\mu_i = f(x_i).$$

پشیمانی نسبت به بهینه‌ی پیوسته را به‌صورت

$$R(n) := \sum_{t=1}^n \mathbb{E}[f^* - f(X_t)],$$

$$f^* := \sup_{x \in \mathcal{X}} f(x).$$

تعریف می‌کنیم.

۲.۱.۵ گام اول: کنترل خطای گسسته‌سازی با لیپ‌شیتز

لم ۱ (خطای تقریب شبکه). اگر N_ϵ یک ϵ -پوشش باشد، و f با ثابت L لیپ‌شیتز باشد، آنگاه

$$0 \leq f^* - f_\epsilon^* \leq L\epsilon, \quad f_\epsilon^* := \max_{x \in N_\epsilon} f(x).$$

اکنون پشیمانی را به دو جزء می‌شکنیم:

$$\begin{aligned} R(n) &= \sum_{t=1}^n (\mathbb{E}[f^* - f_\epsilon^*]) + \sum_{t=1}^n (\mathbb{E}[f_\epsilon^* - f(X_t)]) \\ &\leq n \times (\mathbb{E}[f^* - f_\epsilon^*]) + R_n^\epsilon, \end{aligned}$$

که در آن

$$R_n^\epsilon := \sum_{t=1}^n (\mathbb{E}[f_\epsilon^* - f(X_t)])$$

پشیمانی نسبت به بهترین نقطه روی شبکه است. بنابراین با لم ۱ داریم:

$$R(n) \leq L\epsilon n + R_n^\epsilon.$$

۳.۱.۵ گام دوم: کران مستقل از فاصله برای UCB1 روی K بازو

$$R(n) \leq L n^{\frac{d+1}{d+2}} + 4\sqrt{2\ln(n)} n^{\frac{d+1}{d+2}} + \left(1 + \frac{\pi^2}{3}\right) n^{\frac{d}{d+2}}.$$

این همان کرانی است که در «تلاش اول» به آن رسیدیم.

در مسئله‌ی گسسته با K بازو و پاداش‌های $[0, 1]$ ، الگوریتم UCB1 مطابق [۱] برای هر بازوی زیربینه i با

$$\Delta_i := \mu^* - \mu_i > 0$$

تضمین می‌کند:

$$\mathbb{E}[T_i(T)] \leq \frac{8 \ln T}{\Delta_i^2} + 1 + \frac{\pi^2}{3}. \quad (*)$$

از این رابطه می‌توان یک کران «مستقل از فاصله» استخراج کرد.

لم ۲ (کران مستقل از فاصله برای UCB1). در مسئله‌ی گسسته با K بازو و پاداش‌های کران‌دار در $[0, 1]$ ، پشیمانی مورد انتظار UCB1 پس از n گام ارضا می‌کند:

$$R_n^\epsilon \leq 4\sqrt{2K_\epsilon n \ln(n)} + \left(1 + \frac{\pi^2}{3}\right) K_\epsilon.$$

۴.۱.۵ ترکیب دو گام و بهینه‌سازی ϵ

برای $\mathcal{X} = [0, 1]^d$ (با متریک $\|\cdot\|_\infty$)، یک ϵ -پوشش متناهی با

$$K_\epsilon = |N_\epsilon| \leq \left\lceil \frac{1}{\epsilon} \right\rceil^d \leq \left(\frac{1}{\epsilon} + 1\right)^d$$

وجود دارد؛ در نتیجه از مرتبه‌ی ϵ^{-d} است. با ترکیب لم ۱ و لم ۲ به دست می‌آوریم:

$$R(n) \leq L\epsilon n + 4\sqrt{2K_\epsilon n \ln(n)} + \left(1 + \frac{\pi^2}{3}\right) K_\epsilon.$$

با جایگذاری $K_\epsilon \approx \epsilon^{-d}$ و انتخاب

$$\epsilon := n^{-\frac{1}{d+2}}, \quad \Rightarrow \quad K_\epsilon = \epsilon^{-d} = n^{\frac{d}{d+2}},$$

داریم:

$$Z_x := nf(x) - \sum_{t=1}^n f(X_t)$$

را در نظر گرفت. این کمیت از این جهت وسوسه‌انگیز است که اگر $x^* \in \arg \max_{x \in \mathcal{X}} f(x)$ باشد، آنگاه

$$Z_{x^*} = nf(x^*) - \sum_{t=1}^n f(X_t)$$

پس در نهایت:

۲.۵ تلاش دوم (ناموفق): بازنویسی پشیمانی به صورت کران از بالا برای امید سوپریم یک فرایند

انگیزه‌ی این تلاش استفاده از لم زیر بود که برای یک فرایند تصادفی لپ‌شیتز و زیرگاوسی، امید سوپریم را با عدد پوشش کنترل می‌کند. به طور خلاصه، اگر $\{Z_x\}_{x \in \mathcal{X}}$ فرایندی لپ‌شیتز و زیرگاوسی باشد، آنگاه کرانی از شکل

$$\mathbb{E}\left[\sup_{x \in \mathcal{X}} Z_x\right] \leq \epsilon \mathbb{E}[C] + \sqrt{2\sigma^2 \log N(\mathcal{X}, d, \epsilon)}$$

برقرار است که در آن C ضریب لپ‌شیتز و σ پارامتر زیرگوسی فرایند است.

۱.۲.۵ ایده‌ی کلی و مانع اصلی

برای به کارگیری چنین لمی، باید پشیمانی افق ثابت n را به شکلی از نوع

$$\mathbb{E}\left[\sup_{x \in \mathcal{X}} Z_x\right] \quad \text{یا حداقل} \quad R(n) \leq \mathbb{E}\left[\sup_{x \in \mathcal{X}} Z_x\right]$$

کاهش داد؛ به گونه‌ای که $\{Z_x\}_{x \in \mathcal{X}}$ (۱) نسبت به x لپ‌شیتز باشد و (۲) زیرگاوسی باشد.

۲.۲.۵ یک مثال «بد» برای شهود

برای ایجاد شهود، می‌توان به طور صوری کمیتی مانند

۳.۲.۵ کران بدیهی پشیمانی

از آنجا که پاداش‌ها کران‌دارند، پشیمانی در هر گام حداکثر ۱ است؛ بنابراین

$$0 \leq \sum_{t=1}^n (f^* - f(X_t)) \leq n, \quad \Rightarrow \quad R(n) \leq n.$$

این بدترین کران عمومی ممکن (بدون استفاده از ساختار بیشتر) است.

۴.۲.۵ جمع‌بندی نتیجه‌ی این تلاش

در نهایت، با وجود تلاش برای ساختن یک فرایند $\{Z_x\}_{x \in \mathcal{X}}$ که هم لیپ‌شیتز و هم زیرگاوسی باشد و بتوان پشیمانی را به امید سوپریم آن مرتبط کرد، کران‌های حاصل از کاربرد لم فوق در بهترین حالت به نرخ مرتبه‌ی $O(n)$ منجر می‌شدند. به همین دلیل، جزئیات محاسبات این مسیر در ادامه ارائه نمی‌شود.

پیوست‌ها

اثبات لم ۱

اثبات. به دلیل $N_\epsilon \subset \mathcal{X}$ بدیهی است که $f_\epsilon^* \leq f^*$. برای کران بالا، $x^* \in \arg \sup_{x \in \mathcal{X}} f(x)$ را در نظر بگیرید (یا دنباله‌ی بهینه‌ساز). طبق پوشش بودن، $\tilde{x}^* \in N_\epsilon$ وجود دارد به‌طوری که $d(x^*, \tilde{x}^*) \leq \epsilon$. پس با لیپ‌شیتز بودن:

$$f(x^*) \leq f(\tilde{x}^*) + L\epsilon \leq f_\epsilon^* + L\epsilon.$$

چون $f^* = f(x^*)$ ، نتیجه حاصل می‌شود. $\square$

اثبات لم ۲

اثبات. بازوهای بهینه را با $f_\epsilon^* := \mu_\epsilon^*$ و فاصله‌ها را با Δ_i $\mu_\epsilon^* - \mu_i \geq 0$ تعریف کنید. آنگاه

$$R_n^\epsilon = \sum_{i=1}^{K_\epsilon} \Delta_i \mathbb{E}[T_i(n)].$$

یک آستانه $\alpha > 0$ اختیار کنید و بازوها را به دو دسته تقسیم کنید.

همان «پشیمانی شبه‌پاداش» (با جایگزینی Y_t به جای $f(X_t)$) را بازتولید می‌کند. همچنین اگر f لیپ‌شیتز باشد، برای هر $x, x' \in \mathcal{X}$ داریم

$$|Z_x - Z_{x'}| = n |f(x) - f(x')| \leq (nL) d(x, x'),$$

پس $\{Z_x\}$ نسبت به متریک d لیپ‌شیتز است.

همچنین توجه کنید، Z_x کران‌دار هم هست چرا که $f(x) \in [0, 1]$ و هر جمله‌ی $f(X_t)$ نیز در همین بازه است، برای هر x داریم

$$-n \leq Z_x = n f(x) - \sum_{t=1}^n f(X_t) \leq n,$$

بنابراین $\{Z_x\}_{x \in \mathcal{X}}$ یک فرایند کران‌دار (و در نتیجه زیرگاوسی) است.

با این حال، این انتخاب مشکلی اساسی دارد چرا که Z_x مرکزی نیست، یعنی به طور کلی

$$\mathbb{E}[Z_x] = n f(x) - \sum_{t=1}^n \mathbb{E}[f(X_t)] \neq 0,$$

و این با یکی از شرایط لازم در لم یادشده (که روی فرایندهای زیرگاوسی مرکزدار اعمال می‌شود) سازگار نیست.

اگر بخواهیم آن را مرکز کنیم، می‌توانیم

$$\tilde{Z}_x := Z_x - \mathbb{E}[Z_x]$$

را تعریف کنیم. در این صورت

$$\begin{aligned} \tilde{Z}_x &= (n f(x) - \sum_{t=1}^n f(X_t)) \\ &\quad - (n f(x) - \sum_{t=1}^n \mathbb{E}[f(X_t)]) \\ &= - \sum_{t=1}^n f(X_t) + \sum_{t=1}^n \mathbb{E}[f(X_t)], \end{aligned}$$

که دیگر به x وابسته نیست. بنابراین

$$\sup_{x \in \mathcal{X}} \tilde{Z}_x = \tilde{Z}_x \quad \text{و} \quad \mathbb{E} \left[\sup_{x \in \mathcal{X}} \tilde{Z}_x \right] = \mathbb{E}[\tilde{Z}_x] = 0.$$

در نتیجه، به کارگیری آن لم در بهترین حالت فقط یک کران صفر برای کمیت مرکزی $\mathbb{E}[\sup_x \tilde{Z}_x]$ می‌دهد، در حالی که پشیمانی مورد نظر ما به $\sup_x Z_x$ مربوط است و این رویکرد عملاً کران مفیدی برای پشیمانی فراهم نمی‌کند.

References

- [۱] Peter Auer, Nicolò Cesa-Bianchi, and Paul Fischer. Finite-time analysis of the multi-armed bandit problem. *Machine Learning*, ۲۵۶–۲۳۵:(۳–۲)۴۷.۲۰۰۲

دسته‌ی اول: $\Delta_i \leq \alpha$. برای این بازوها داریم

$$\Delta_i T_i(n) \leq \alpha T_i(n)$$

و لذا

$$\sum_{\Delta_i \leq \alpha} \Delta_i \mathbb{E}[T_i(n)] \leq \alpha \sum_{\Delta_i \leq \alpha} \mathbb{E}[T_i(n)] \leq \alpha n.$$

دسته‌ی دوم: $\Delta_i > \alpha$. برای این بازوها از $(\star)$ استفاده می‌کنیم:

$$\begin{aligned} \Delta_i \mathbb{E}[T_i(n)] &\leq \Delta_i \left(\frac{8 \ln(n)}{\Delta_i^2} + 1 + \frac{\pi^2}{3} \right) \\ &= \frac{8 \ln(n)}{\Delta_i} + \left(1 + \frac{\pi^2}{3} \right) \Delta_i. \end{aligned}$$

چون $\Delta_i > \alpha$ و نیز $\Delta_i \leq 1$ (زیرا $\mu_i \in [0, 1]$)، نتیجه می‌شود:

$$\frac{8 \ln(n)}{\Delta_i} \leq \frac{8 \ln(n)}{\alpha}, \quad \left(1 + \frac{\pi^2}{3} \right) \Delta_i \leq \left(1 + \frac{\pi^2}{3} \right).$$

پس

$$\sum_{\Delta_i > \alpha} \Delta_i \mathbb{E}[T_i(T)] \leq \frac{8K_\epsilon \ln(n)}{\alpha} + \left(1 + \frac{\pi^2}{3} \right) K_\epsilon.$$

در مجموع:

$$R_n^\epsilon \leq \alpha n + \frac{8K_\epsilon \ln(n)}{\alpha} + \left(1 + \frac{\pi^2}{3} \right) K_\epsilon.$$

اکنون $\alpha := \sqrt{\frac{8K_\epsilon \ln(n)}{n}}$ را انتخاب می‌کنیم تا دو جمله‌ی اول برابر شوند؛ آنگاه

$$\begin{aligned} \alpha n &= \sqrt{8K_\epsilon n \ln(n)}, \\ \frac{8K_\epsilon \ln(n)}{\alpha} &= \sqrt{8K_\epsilon n \ln(n)}, \end{aligned}$$

و بنابراین

$$\begin{aligned} R_n^\epsilon &\leq 2\sqrt{8K_\epsilon n \ln(n)} + \left(1 + \frac{\pi^2}{3} \right) K_\epsilon \\ &= 4\sqrt{2K_\epsilon n \ln(n)} + \left(1 + \frac{\pi^2}{3} \right) K_\epsilon. \end{aligned}$$

□